

NLP Mimarisi ve Yöntem Haritası

Katılım Bankacılığı Kampanya Metinlerinden Bilgi Çıkarımı
Doğal dil işleme yöntemlerinin şartname maddeleriyle eşlenmesi

5 Ağustos 2026

1 Amaç ve Kapsam

Bu belge, geliştirilen çözümde **doğal dil işlemenin tam olarak nerede ve hangi yöntemle kullanıldığını** tanımlar. Amaç, şartnamenin “NLP yöntemlerinin probleme uygun kullanılması”, “metin ön işleme adımlarının doğru uygulanması” ve “bilgi çıkarımı yaklaşımının başarısı” değerlendirme maddelerine izlenebilir bir karşılık vermektir.

1.1 Kapsam dışı olanlar

Dürüstlük açısından önce sınır çizilmelidir. Aşağıdaki bileşenler yazılım mühendisliğidir, doğal dil işleme değildir ve bu belgede NLP olarak sunulmamaktadır:

- Karşılaştırma motoru ve sıralama mantığı (aritmetik normalizasyon)
- Dashboard, arayüz ve görselleştirme katmanı
- Veri modeli, kalıcı depo ve API sözleşmesi
- On-premise dağıtım mimarisi

Doğal dil işleme, yalnızca Bölüm 3’te tanımlanan sekiz adımlık metin işleme hattında yer alır.

2 Şartname Maddeleriyle Eşleme

Madde	İstenen	NLP yöntemi	Modül	Durum
5.1	Veri toplama	Gövde metni çıkarma, kalıp (boilerplate) temizliği	—	Eksik
5.2	Farklı ve örtük ifade biçimleri	Eşanlımlı kalıp sözlüğü + kural desenleri + dil modeli	lexicon.ts	Kısmi
5.3	Finansal bilgi çıkarımı	Bilgi çıkarımı: değer tanıma, birim çözümleme, aralık ve olumsuzluk kapsamı	extract.ts	Kısmi
5.4	Kampanya türü belirleme	Metin sınıflandırma (TF-IDF + doğrusal model)	—	Eksik
5.5	Katılım terminolojisi	Sözlükbirim tabanlı normalizasyon, çekim ekine tolerans	lexicon.ts	Hazır
5.6	Standart formata dönüştürme	Sayı, para birimi ve tarih normalizasyonu; yazılı sayı ayrıştırma	normalize.ts	Hazır

Madde	İstenen	NLP yöntemi	Modül	Durum
5.8	Veri ön işleme	Temizleme, normalizasyon, cümle bölütleme, belirteçleme	<code>normalize.ts</code> , <code>segment.ts</code>	Hazır
—	Kanıt zorunluluğu	Cümle düzeyinde hizalama (birebir / normalize / örtüşme)	<code>align.ts</code>	Hazır
—	Chatbot	Niyet sınıflandırma + slot doldurma + sorguya çevirme	—	Eksik
—	Model başarısı	Alan bazlı kesinlik / duyarlılık / F1 ölçümü	—	Eksik

3 İşleme Hattı

Metin, kaynaktan şemaya kadar sekiz adımdan geçer. Adım sırası tesadüfi değildir: kural tabanlı katman dil modelinden *önce* çalışır, böylece kolay vakalar deterministik olarak çözülür ve dil modeli yalnızca varyasyonlu ifadeler için devreye girer.

- Ön işleme** — `normalize.ts`
Gövde metni çıkarma, Unicode NFC, tipografik tırnak ve tire sadeleştirme, bölünmez boşluk temizliği, Türkçe yerel ayarlı küçültme, ASCII katlama.
- Cümle bölütleme** — `segment.ts`
Ondalık ayırıcı, tarih, binlik ayırıcı ve kısaltma korumalı bölütleme; her cümlenin kaynak metindeki karakter aralığı saklanır.
- Terminoloji eşleme** — `lexicon.ts`
Konvansiyonel terimlerin katılım karşılıklarına eşlenmesi; `terim_esleme_uygulandi` bayrağının belirlenmesi.
- Kural tabanlı bilgi çıkarımı** — `extract.ts`
Oran ve periyot, vade, tahsis ücreti (olumsuzluk dâhil), tutar aralığı.
- Metin sınıflandırma** — *planlanan*
Kampanya türünün sekiz sınıftan birine atanması.
- Dil modeli** — yerel, şema kısıtlı üretim
Yalnızca dördüncü adımda boş kalan alanlar için çağrılır.
- Çapraz doğrulama** — `extract.ts`
Kural ve model çıktılarının karşılaştırılması; uyumsuzlukta güven skorunun düşürülmesi.
- Kanıt hizalama** — `align.ts`
Her alanın dayandığı cümlenin kaynak metinde konumlandırılması.

4 Yöntemlerin Ayrıntısı

4.1 Türkçe metin normalizasyonu

JavaScript'in yerleşik `toLowerCase()` metodu Türkçe alfabesini tanımaz. Büyük İ harfi küçültülürken `i` artı ayrı bir birleşik nokta karakterine (U+0307) dönüşür; noktasız `I` ise ASCII `i` olur:

Girdi	toLowerCase()	Sonuç
FAİZ ORANI	fai [U+0307] z oranı	Terim yakalanamaz
DOSYA MASRAFI	dosya masrafi	Terim yakalanamaz

Bu nedenle tüm küçültme işlemleri **tr-TR** yereliyle yapılır ve eşleştirme, aksan ile şapkayı katlayan ayrı bir anahtar üzerinden yürütülür. Böylece “kâr payı” ile “kar payı” aynı terime çözümlenir.

Sayısal normalizasyon üç biçimi tek değere indirir: Türkçe ondalık (2,05), İngilizce ondalık (2.05) ve binlik ayrıçlı (1.000.000). Ayrıca yazıyla yazılmış Türkçe sayılar çözümlenir; “beş yüz Türk Lirası dosya masrafı” ifadesi 500 değerini üretir.

4.2 Cümle bölütleme

Naif nokta bölme finans metinlerinde başarısız olur. Bölütleyici şu kalıpları cümle sonu saymaz: ondalık ayrıçlı (%2,05), tarih (31.12.2026), binlik ayrıçlı (1.000.000), Türkçe kısaltmalar (vb., Sn., md.) ve baş harf kullanımı (A. Bankası). Her cümle için (başlangıç, bitiş) karakter aralığı üretilir; kanıt hizalama bu aralıklara dayanır.

4.3 Sözlükbirim eşleme ve morfolojik tolerans

Türkçe eklemeli bir dildir; sabit kelime araması yetersizdir. Sözlük girdileri kök hâlinde tutulur ve eşleştirme, kökün ardından en fazla altı harflik çekim ekine izin veren bir desenle yapılır. Böylece *faiz*, *faizi*, *faizde*, *faizli* tek bir girdiyle yakalanır.

4.4 Olumsuzluk tespiti

“Tahsis ücreti alınmaz” ifadesi şemada 0 değerine karşılık gelir; pozitif bir sayı aranarak bulunmaz. Türkçede olumsuzluk çekim ekiyle taşınır:

Ek	Örnek	Değer
-maz / -mez	alınmaz, edilmez	0
-mıyor / -muyor	alınmıyor	0
-mama- / -meme-	alınmamaktadır	0
-makta / -mekte	alınmaktadır	pozitif

Son satır kritiktir: “alınmaktadır” *olumludur*. Naif bir “alınm” araması bu iki durumu ayırt edemez ve ücreti hatalı biçimde sıfırlar.

4.5 Kural tabanlı bilgi çıkarımı

Birinci katman deterministik, milisaniyelik ve tekrarlanabilir. Dört alanı bağlam denetimiyle çıkarır: oran ifadesinin gerçekten kâr payına ait olup olmadığı, vade ifadesinin taksit sayısı ile karışıp karışmadığı, ücret cümlesinin tutar cümlesinden ayrılması gibi denetimler uygulanır.

Şartname kuralı doğrudan kodlanmıştır: metinde “aylık” veya “yıllık” geçmiyorsa periyot **belirsiz** atanır ve o alanın güven skoru en fazla 0,5 olur.

4.6 Kanıt hizalama

Modelin döndürdüğü alıntı, kaynak metinle birebir aynı olmayabilir. Hizalayıcı üç aşamalıdır: birebir arama, normalize edilmiş metin üzerinde arama, ve cümle düzeyinde belirteç örtüşmesi. Üçüncü aşamada Jaccard benzerliği kullanılır:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Burada A alıntının, B aday cümlelerin belirteç kümesidir. Eşik değeri $J \geq 0,45$ olarak belirlenmiştir. Çakışan aralıklarda yüksek skorlu hizalama kazanır.

4.7 Metin sınıflandırma (planlanan)

Kampanya türü sekiz sınıfa ayrılacaktır. Yöntem, belirteç ağırlıklandırması ve doğrusal bir sınıflandırıcıdır:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \log \frac{N}{\text{df}(t)}$$

Bu tercih bilinçlidir: yerelde saniyeler içinde eğitilir, GPU gerektirmez, kararı açıklanabilir (hangi terimin hangi sınıfa katkı verdiği görülebilir) ve on-premise kısıtıyla uyumludur.

4.8 Çapraz doğrulama

Kural katmanı ile dil modeli bağımsız iki kaynaktır. Değerler %1 tolerans içinde uyuyorsa güven korunur; uyumuyorsa güven skoru yarıya indirilir ve kayıt manuel doğrulama kuyruğuna alınır. Bu, tek bir modelin kendi beyan ettiği güven skoruna bağımlı kalmayı önler.

4.9 Chatbot için dil işleme (planlanan)

Chatbot, serbest üretim yerine yapılandırılmış veriyi sorgular. Gerekli dil işleme adımları:

- **Niyet sınıflandırma:** tek ürün sorgusu, karşılaştırma, listeleme, tanım sorusu
- **Slot doldurma:** banka adı, ürün türü, kriter, sayısal kısıt
- **Sorguya çevirme:** slotlardan veritabanı sorgusu üretimi
- **Cevap üretimi:** şablon tabanlı, kaynak cümle ve güven skoru ekli

5 Değerlendirme Kriterleriyle İlişki

Kriter	Karşıllayan bileşen
NLP yöntemlerinin probleme uygun kullanılması	Katmanlı hat: kural $\rightarrow$ model $\rightarrow$ çapraz doğrulama
Metin ön işleme adımlarının doğru uygulanması	<code>normalize.ts</code> , <code>segment.ts</code>
Bilgi çıkarımı yaklaşımının başarısı	<code>extract.ts</code> + ölçüm seti
Farklı ifade biçimlerini doğru yorumlayabilmesi	Morfolojik tolerans, eşanlı kalıp sözlüğü, dil modeli
Eksik/farklı yazılmış bilgide doğru sonuç	Olumsuzluk tespiti, yazılı sayı çözümleme, ASCII katlama

6 Ölçüm Planı

Her alan için ayrı ayrı hesaplanacaktır:

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

Bir alan, altın değerle tam eşleştiğinde doğru sayılır; sayısal alanlarda %1 tolerans uygulanır. Ölçüm üç yapılandırmada tekrarlanır: yalnızca kural katmanı, yalnızca dil modeli, ve katmanlı hibrit. Bu karşılaştırma, hibrit mimarinin katkısını sayısal olarak gösterir.

7 Eksikler ve İş Planı

İş	Süre	Karşıladığı madde
Kural motorunu birinci katmana taşıma	Yarım gün	5.3, teknik kriter
Örtük ifade kalıp sözlüğü	Birkaç saat	5.2
Kampanya türü sınıflandırıcı	Yarım gün	5.4
Ölçüm seti ve F1 raporu	Yarım gün	Model başarısı
Ön işleme hattının toplama katmanına bağlanması	Yarım gün	5.1, 5.8
Chatbot niyet ve slot katmanı	1,5 gün	Senaryo kapsamı

Toplam yaklaşık dört iş günü. Sıralamada ilk madde önceliklidir: kural katmanının öne alınması hem gecikmeyi düşürür hem de sonraki ölçümler için temel oluşturur.